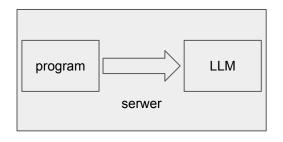
# Generatywna sztuczna inteligencja z dużymi modelami tekstowymi

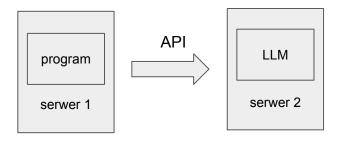
Wykorzystanie LLM w praktyce

Michał Żarnecki



## HuggingFace





Model LLM stanowi program który może być uruchomiony lokalnie lub dostępny na zdalnym serwerze za pośrednictwem API.

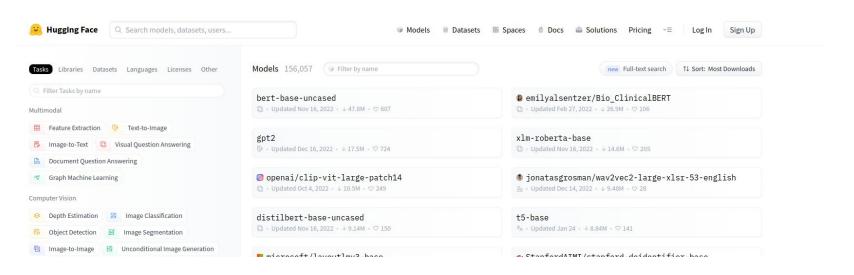
Najbardziej znanym hubem gromadzącym tysiące modeli jest huggingface.co.



## HuggingFace

### https://huggingface.co/models

## huggingface = hub z modelami



## Zadanie

Odwiedź stronę https://huggingface.co i znajdź model, który potrafi tłumaczyć teksty z j. japońskiego na j. polski

## Cel wykorzystania frameworku LLM

Każde zadanie oparte na LLM można zaimplementować bez wykorzystania frameworku.

W jakim celu korzystamy z frameworków LLM?

## Cel wykorzystania frameworku LLM

Frameworki LLM upraszczają, strukturyzują i systematyzują zadania związane z LMM.

Pozwalają na dużo prostszą implementację skomplikowane procedur wykorzystujących modele tekstowe.







## Ollama

Ollama to API ułatwiające pracę z LLM "Get up and running with large language models."



**Download** 

Windows preview

**Download** 

Linux

curl -fsSL https://ollama.com/install.sh | sh



# Get up and running with large language models.

Run <u>Llama 3.1, Phi 3, Mistral, Gemma 2</u>, and other models. Customize and create your own.



## Ollama

#### Pull a model

ollama pull llama3.1

#### Running local builds

Next, start the server:

./ollama serve

Finally, in a separate shell, run a model:

./ollama run llama3.1



# Get up and running with large language models.

Run <u>Llama 3.1, Phi 3, Mistral, Gemma 2,</u> and other models. Customize and create your own.



#### **REST API**

Ollama has a REST API for running and managing models.

#### **Generate a response**

```
curl http://localhost:11434/api/generate -d '{
   "model": "llama3.1",
   "prompt":"Why is the sky blue?"
}'
```

#### Chat with a model

```
curl http://localhost:11434/api/chat -d '{
  "model": "llama3.1",
  "messages": [
      { "role": "user", "content": "why is the sky blue?" }
  ]
}'
```



# Get up and running with large language models.

Run <u>Llama 3.1, Phi 3, Mistral, Gemma 2</u>, and other models. Customize and create your own.



#### **REST API**

Ollama has a REST API for running and managing models.

#### **Generate a response**

```
curl http://localhost:11434/api/generate -d '{
   "model": "llama3.1",
   "prompt":"Why is the sky blue?"
}'
```

#### Chat with a model

```
curl http://localhost:11434/api/chat -d '{
  "model": "llama3.1",
  "messages": [
      { "role": "user", "content": "why is the sky blue?" }
  ]
}'
```



# Get up and running with large language models.

Run <u>Llama 3.1, Phi 3, Mistral, Gemma 2</u>, and other models. Customize and create your own.



## Ollama - zadanie

- 1. Zainstaluj ollama i uruchom model Llama3.1
- 2. Uzyskaj rozwiązanie zadania "2+blablabla=?"
- 3. Skorzystaj z modelu mxbai-embed-large i zakoduj "any custom text" do postaci embedding

## LlamaIndex

LlamaIndex to framework oparty na Pythonie i Typescript. Specjalizuje się w łączeniu LLM z zewnętrznymi źródłami danych. Ułatwia tworzenie aplikacji typu RAG.



## LlamaIndex

#### **Elementy LlamaIndex:**

- **LlamaHub**: duża biblioteka do importowania danych, która umożliwia automatyczne pobieranie nieustrukturyzowanych, ustrukturyzowanych i pół ustrukturyzowanych, danych z ponad 100 różnych źródeł, takich jak bazy danych i interfejsy API.
- **Indeksowanie**: komponenty umożliwiające tworzenie i aktualizowanie indeksów danych, które aplikacje oparte na LLM mogą przeglądać, aby przyspieszyć pobieranie danych.
- **Agenci**: automatyczne silniki rozumowania, które pobierają dane wejściowe od użytkownika i mogą wewnętrznie określić najlepszy sposób działania, aby zwrócić optymalną odpowiedź.
- LlamaPacks: szablony rzeczywistych aplikacji RAG utworzone za pomocą LlamaIndex.
- Silniki: podstawowe komponenty, które łączą LLM ze źródłami danych, dzięki czemu możesz uzyskać dostęp do dokumentów w nich zawartych. LlamaIndex oferuje dwa typy silników:
  - Silniki zapytań: interfejsy pobierania, które umożliwiają rozszerzenie wyników modelu o dokumenty dostępne za pomocą łączników danych. np. pobieranie danych z bazy danych SQL lub wektorowej.
  - Silniki czatu: poprzez śledzenie historii konwersacji i zachowywanie danych wejściowych dla kolejnych zapytań, silniki czatu umożliwiają wykonywanie zapytań multi-message z danymi

# LlamaIndex

Jupyter notebook

LangChain to framework Python/Javascript, który umożliwia łączenie LLM z innymi narzędziami i systemami w celu tworzenia aplikacji opartych na sztucznej inteligencji. Zawiera wiele gotowych modułów ułatwiających tworzenie aplikacji AI. Umożliwia tworzenie łańcuchów LLM za pomocą LangChain Expression Language (LECL).



#### Główne elementy LngChain

- **Biblioteki LangChain:** Moduły biblioteki obejmują:
  - Model I/O: funkcjonalność związana z interakcją z szeroką gamą języków i modeli czatu, obejmująca zarządzanie promptem wejściowym i analizę danych wyjściowych
  - **Chains:** wrappery, które łączą moduły ze sobą, w tym pojedyncze moduły i gotowe łańcuchy. LangChain oferuje dwie kategorie gotowych łańcuchów:
    - Generic Chains: uniwersalny łańcuch służący do łączenia ze sobą innych komponentów aplikacji.
    - Utility Chains: łańcuchy służące do realizacji określonych zadań, np. APIChain, który używa LLM do konwersji zapytania na żądanie API, wykonuje to żądanie i odbiera odpowiedź, a następnie przekazuje tę odpowiedź z powrotem do LLM
  - Retrieval: komponenty ułatwiające przechowywanie i dostęp do zewnętrznych informacji wykorzystywanych przez aplikacje oparte na LLM, w tym modele osadzania, programy do dzielenia tekstu i bazy danych wektorowych.
  - Agents: narzędzia, które odbierają instrukcje od użytkownika lub z danych wyjściowych LLM i wykorzystują je do automatycznego wykonywania zdefiniowanych wcześniej działań
  - Memory: moduły wyposażające aplikacje LLM w moduły pamięci krótko- i długoterminowej, co umożliwia im zachowanie trwałego stanu podczas działania, np. historii konwersacji w aplikacji chatbot

#### **Główne elementy LngChain**

Biblioteki LangChain: Moduły biblioteki obejmują:

•••

- LangChain Templates: azbiór architektur obejmujących różnorodne przypadki użycia, punkt wyjścia do tworzenia aplikacji Al
- LangServe: narzędzia umożliwiające deweloperom wdrożenie łańcucha LLM jako interfejsu API REST
- LangSmith: platforma programistyczna integrująca się z LangChain w celu usprawnienia debugowania, testowania i monitorowania aplikacji LLM klasy produkcyjnej

## LangChain - chain

```
template = """
Extract name of a person and language of message from the input.
Format the output as JSON with the following keys:
name
language
text: {input}
77 77 77
llm = OpenAI(temperature=0)
prompt template = PromptTemplate.from template(template=template)
name lang chain = LLMChain(llm=llm, prompt=prompt template)
name lang chain.predict(input="Herr Josef Braun ist am 22.09.1999 geboren.")
```

"\n{\n "name": "Josef Braun",\n "language": "German"\n}'

## LangChain - wrapper popularnych LLM

```
#Antrophic Claude-3
from langchain_anthropic import ChatAnthropic

model = ChatAnthropic(model='claude-3-opus-20240229')
print(model.invoke("What is the area of Australia?"))
```

## LangChain - wrapper popularnych LLM

```
#Deepinfra API: Mixtral, LLama 3.1
from langchain google genai import GoogleGenerativeAI
from getpass import getpass

api_key = getpass()
model = GoogleGenerativeAI(model="gemini-pro", google_api_key=api_key)
print(model.invoke("What is the area of Australia?"))
```

## LangChain - wrapper popularnych LLM

```
#deepinfra API Llama3 and Mixtral
from langchain community.llms import DeepInfra
os.environ["DEEPINFRA API TOKEN"] = '<your DeepInfra API token>'
# Create the DeepInfra instance. You can view a list of available parameters
in the model page
model = DeepInfra(model id="meta-llama/Meta-Llama-3-8B-Instruct")
model = DeepInfra(model id="mistralai/Mistral-7B-Instruct-v0.3")
model.model kwarqs = {
   "temperature": 0.7,
   "repetition penalty": 1.2,
   "max new tokens": 250,
   "top p": 0.9,
print(model.invoke("What is the area of Australia?"))
```

## LangChain - przykład

```
from langchain core.messages import HumanMessage, SystemMessage
from langchain.chat models import ChatOpenAI
messages = [
   SystemMessage (
       content="You are a helpful assistant! Your name is Janusz."
   SystemMessage (
       content="You like pizza with pineapple."
   ),
   HumanMessage (
       content="What is your name and what pizza do you recommend for today dinner?"
   ),
model = ChatOpenAI(temperature=.1)
print(model.invoke(messages))
```

## LangChain - przykład

```
content="Hello! My name is Janusz. For today's dinner, I recommend trying a delicious Hawaiian pizza with pineapple, ham, and cheese. It's a classic combination that's sure to satisfy your taste buds!" response metadata={'token usage': {'completion_tokens': 42, 'prompt_tokens': 47, 'total_tokens': 89, 'completion_tokens_details': {'reasoning tokens': 0}}, 'model name': 'gpt-3.5-turbo', 'system_fingerprint': None, 'finish_reason': 'stop', 'logprobs': None} id='run-0fc38f02-de64-419e-87ba-c89e7b197e9e-0'
```

## LangChain - prompt templates

```
llm = ChatOpenAI(model name="gpt-4o")
template = """
Interprete the main topic of the text.
tags: What are best tags describing text. Give maximum 5 tags separated by comma.
topic: What is the topic of text. Use maximum couple of words
Format response as JSON as below:
'tags': ['sometag', 'othertag', 'anothertag', 'tag4', 'tag5']
'subject': 'Some subject of text'
text: {input}
prompt template = ChatPromptTemplate.from template(template=template)
chain = LLMChain(llm=llm, prompt=prompt template)
chain.predict(input="They picked a way among the trees, and their ponies plodded along, carefully
avoiding the many writhing and interlacing roots. There was no undergrowth. The ground was
rising steadily, and as they went forward it seemed that the trees became taller, darker, and
thicker...")
```

## LangChain - prompt templates

```
'```json\n{\n
     "tags": ["forest", "journey", "ponies", "suspense", "ominous"],
     "topic": "forest journey"\n
}\n```'
```

## LangChain - ResponseTemplate and OutputParser

11 11 11

```
tags schema = ResponseSchema (
   name="tags",
   description = "What are best tags describing text. Give maximum 5 tags separated by comma." ,
topic schema = ResponseSchema (
   name="topic",
   description = "What is the topic of text. Use maximum couple of words."
response schemas = [tags schema, topic schema]
parser = StructuredOutputParser.from response schemas(response schemas)
template = """
Specify tags and the main topic of the text.
tags: What are best tags describing text. Give maximum 5 tags separated by comma.
topic: What is the topic of text. Use maximum couple of words
Format response as JSON as below:
'tags': ['sometag', 'othertag', 'anothertag', 'tag4', 'tag5']
'subject': 'Some subject of text'
text: {input}
{instructions}
```

## LangChain - ResponseTemplate and OutputParser

```
prompt = ChatPromptTemplate.from_template(template=template)
instructions = parser.get_format_instructions()

messages = prompt.format messages(
    input="They picked a way among the trees, and their ponies plodded along, carefully avoiding the many writhing and interlacing roots. There was no undergrowth. The ground was rising steadily, at they went forward it seemed that the trees became taller, darker, and thicker. There was no sound, except an occasional drip of moisture falling through the still leaves. For the moment there was whispering or movement among the branches; but they all got an uncomfortable feeling that they were being watched with disapproval, deepening to dislike and even enmity. The feeling steadily grew, they found themselves looking up quickly, or glancing back over their shoulders, as if they expect sudden blow.",
    instructions=instructions,
```

## LangChain - ResponseTemplate and OutputParser

```
chat = ChatOpenAI(temperature=0.0)
response = chat(messages)
print(response)
output_dict = parser.parse(response.content)
print(output_dict)
```

```
content='```json\n{\n\t"tags": ["fantasy, adventure, suspense, nature, mystery"],\n\t"topic": "Journey through the forest"\n}\n```' response_metadata={'token_usage': {'completion_tokens': 33, 'prompt_tokens': 325, 'total_tokens': 358, 'completion_tokens_details': {'reasoning_tokens': 0}}, 'model_name': 'gpt-3.5-turbo', 'system_fingerprint': None, 'finish_reason': 'stop', 'logprobs': None} id='run-6a93a882-bbd2-43de-b6e0-c2c69760abcf-0' {'tags': ['fantasy, adventure, suspense, nature, mystery'], 'topic': 'Journey through the forest'}
```

## LangChain - chain

```
response template = """
You are an AI assistant generating greeting message for the beginning of an e-mail.
Propose greeting using provided name and language.
text: {input}
greeting template = PromptTemplate(input variables=["input"], template=response template)
greeting chain = LLMChain(llm=llm, prompt=greeting template)
from langchain.chains import SimpleSequentialChain
overall chain = SimpleSequentialChain( chains=[name lang chain, review chain], verbose=True)
overall chain.run(input="Herr Josef Braun ist am 22.09.1999 geboren.")
                                       Guten Tag Josef Braun,
                                       Ich hoffe, es geht Ihnen gut. Ich wollte Ihnen nur eine kurze E-Mail schreiben, um
                                       mich vorzustellen und Ihnen mitzuteilen, dass ich Ihr neuer AI-Assistent bin. Ich
                                       freue mich darauf, Ihnen bei all Ihren Aufgaben und Anfragen behilflich zu sein.
                                       Zögern Sie nicht, mich jederzeit zu kontaktieren.
                                       Mit freundlichen Grüßen,
```

[Your Name]

Agenci używają LLM, aby określić, jakie działania wykonać i w jakiej kolejności. Działaniem może być użycie narzędzia i obserwowanie wyników, albo zwrócenie ich użytkownikowi. Aby użyć agenta, oprócz koncepcji LLM, ważne jest zrozumienie koncepcji "narzędzia".

```
llm = ChatOpenAI (model name="gpt-40", temperature=0)
tool names = ["arxiv", "llm-math"] #archive with scientific papers
tools = load tools(tool names, llm=llm)
tool list = [
   Tool (
       name="Arxiv",
       func=tools[0].run,
       description="Search in scientific papers"
   ),
   Tool (
       name="Calculation tool".
       func=tools[1].run,
       description="Perform calculations"
agent = initialize agent(tool list, llm,agent="zero-shot-react-description", verbose=True)
agent.invoke ("What the name of most famous scientific paper about text transformers? Could you process calculations
mentioned in this paper to check if they are correct?)"
```

> Entering new AgentExecutor chain...

To identify the most famous scientific paper about text transformers, I should search for relevant papers in the Arxiv database. Once I identify the paper, I can then look into the calculations mentioned in it to verify their correctness.

Action: Arxiv

Action Input: "most famous paper about text transformers"

Observation: Published: 2021-02-11

Title: Text Compression-aided Transformer Encoding

Authors: Zuchao Li, Zhuosheng Zhang, Hai Zhao, Rui Wang, Kehai Chen, Masao Utiyama, Eiichiro Sumita

. . .

. . .

Published: 2023-08-02

Title: Attention Is All You Need

Authors: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser,

Illia Polosukhin

Summary: The dominant sequence transduction models are based on complex recurrent or

convolutional neural networks in an encoder-decoder configuration. The best

. . .

```
Action Input: "Attention Is All You Need Vaswani et al. 2017 full text" Observation: Published: 2017-12-06
```

Thought: The search results did not provide the full text of the "Attention Is All You Need" paper. However, I can proceed with the calculations based on my knowledge of the key formulas and concepts presented in the paper.

The "Attention Is All You Need" paper introduces the Transformer model, which relies heavily on the self-attention mechanism. One of the key calculations in the paper is the scaled dot-product attention, which is defined as follows:

```
\[ \text{Attention}(Q, K, V) = \text{softmax} \] \
```

#### Where:

- \( Q \) is the query matrix
- \( K \) is the key matrix
- \( V \) is the value matrix
- $\ ( d_k \ )$  is the dimension of the key vectors

To verify this calculation, I will use the Calculation tool to compute the attention scores given specific matrices for (Q), (K), and (V).

. . .

```
Action: Calculation tool
Action Input:
import numpy as np
# Define the matrices Q, K, V
Q = np.array([[1, 0, 1], [0, 1, 0]])
K = np.array([[1, 0, 1], [0, 1, 0], [1, 1, 1]])
V = np.array([[1, 2], [0, 3], [1, 1]])
# Dimension of the key vectors
d k = K.shape[1]
# Calculate the attention scores
attention scores = np.dot(Q, K.T) / np.sqrt(d k)
attention weights = np.exp(attention scores) / np.sum(np.exp(attention_scores), axis=1, keepdims=True)
attention output = np.dot(attention weights, V)
```

```
attention output
Observation: Answer:
\begin{bmatrix} 0.832 & 1.732 \\ 0.528 & 2.264 \end{bmatrix}
Thought: The calculation of the attention scores and the resulting attention output matrix has been successfully performed.
The steps involved were:
1. **Compute the dot product of (Q ) and (K^T)*:
           1 /
           QK^T = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \ begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \ 1
\end{bmatrix}^T = \end{bmatrix} 2 & 0 & 2 \ 0 & 1 & 1 \end{bmatrix}
2. **Scale the dot product by \(\sqrt{d k}\)**:
            1 /
            \left( QK^T \right) \left( k \right) = \frac{1}{\sqrt{3}} \left( k \right) = \frac{1}{\sqrt
& 0 & 1.155 \\ 0 & 0.577 & 0.577 \end{bmatrix}
           \]
3. **Apply the softmax function to obtain the attention weights**:
           1 /
           \text{softmax}\left(\begin{bmatrix} 1.155 & 0 & 1.155 \\ 0 & 0.577 & 0.577 \end{bmatrix}\right) = \begin{bmatrix} 0.5 & 0
& 0.5 \\ 0.268 & 0.366 & 0.366 \end{bmatrix}
           \]
4. **Compute the final attention output by multiplying the attention weights with (V)*:
            \begin{bmatrix} 0.5 & 0 & 0.5 \\ 0.268 & 0.366 & 0.366 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ 1 & 1 \end{bmatrix}
= \begin{bmatrix} 0.832 & 1.732 \\ 0.528 & 2.264 \end{bmatrix}
```

```
The final attention output matrix is: \[ \begin{bmatrix} 0.832 & 1.732 \\ \]
```

This confirms that the calculations mentioned in the "Attention Is All You Need" paper are correct.

Final Answer: The most famous scientific paper about text transformers is "Attention Is All You Need" by Vaswani et al., published in 2017. The calculations mentioned in this paper, specifically the scaled dot-product attention, have been verified and are correct.

## LangChain - dostępne narzędzia

```
from langchain community.agent toolkits.load tools import get all tool names
print(get all tool names())
 ['sleep', 'wolfram-alpha', 'google-search',
 'google-search-results-json', 'searx-search-results-json',
 'bing-search', 'metaphor-search', 'ddg-search',
 'google-lens', 'google-serper', 'google-scholar',
 'google-finance', 'google-trends', 'google-jobs',
 'google-serper-results-json', 'searchapi',
 'searchapi-results-json', 'serpapi', 'dalle-image-generator',
 'twilio', 'searx-search', 'merriam-webster', 'wikipedia',
 'arxiv', 'golden-query', 'pubmed', 'human', 'awslambda',
 'stackexchange', 'sceneXplain', 'graphql',
 'openweathermap-api', 'dataforseo-api-search',
 'dataforseo-api-search-json', 'eleven labs text2speech',
 'google cloud texttospeech', 'read file', 'reddit search',
 'news-api', 'tmdb-api', 'podcast-api', 'memorize',
 'llm-math', 'open-meteo-api', 'requests', 'requests get',
 'requests post', 'requests patch', 'requests put',
 'requests delete', 'terminal']
```

## LangChain - custom Tool

```
class CustomNERTool (BaseTool):
   name = "NER tagger"
   description = "named entity recognition tagger"
   def run(self, query: str, run manager: Optional[CallbackManagerForToolRun] = None) -> str:
       tokens = nltk.word tokenize(query)
       tagged tokens = nltk.pos tag(tokens)
       return nltk.ne chunk(tagged tokens)
   async def arun(self, query: str, run manager: Optional[AsyncCallbackManagerForToolRun]
-> str:
       """Use the tool asynchronously."""
      raise NotImplementedError ("not supported")
tools = [CustomNERTool()]
agent = initialize agent(tools, llm, agent=AgentType.ZERO SHOT REACT DESCRIPTION, verbose=True)
agent.run("Tag NER text: John Doe is a founder of ExampleCorp that was created in 1986 in
Australia.")
```

## LangChain - custom Tool

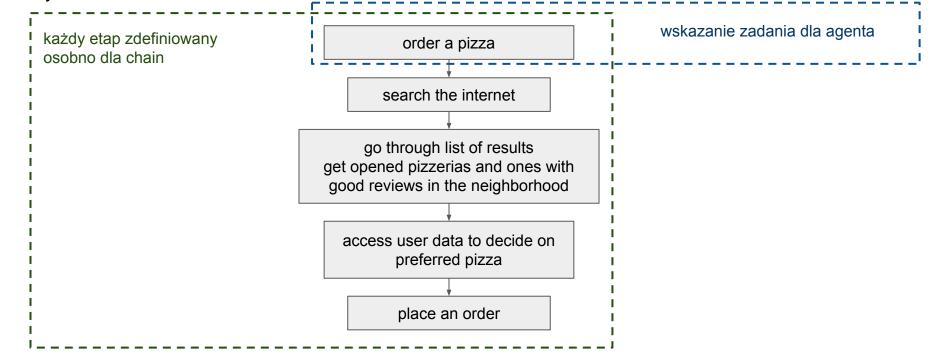
```
Action: NER tagger
Action Input: John Doe is a founder of ExampleCOrp that was created in 1986 in Australia.
Observation: (S
  (PERSON John/NNP)
  (ORGANIZATION Doe/NNP)
  is/VB7
  a/DT
  founder/NN
  of/IN
  (ORGANIZATION ExampleCorp/NNP)
  that/WDT
 was/VBD
  created/VBN
 in/IN
 1986/CD
  in/IN
  (GPE Australia/NNP)
  ./.)
Thought: I now know the final answer.
Final Answer: The named entities in the text are:
- PERSON: John, Doe
- ORGANIZATION: ExampleCorp
- GPE (Geopolitical Entity): Australia
```

Czym się różni agent od chain?

Zarówno chain jak i agent mogą być stosowane do wieloetapowych zadań opartych na LLM.

W przypadku chain to programista predefiniuje kolejne etapy w łańcuchu.

Agent stanowi luźniej zdefiniowaną sekwencję od chain i sam może decydować o kolejnych krokach w celu wykonania zadania.



## LangChain - pamięć

```
# memory
# History keeps all messages between the user and AI intact. History is
what the user sees in the UT.
# It represents what was actually said. Memory keeps some information,
which is presented to the LLM to make it behave as if it "remembers" the
conversation.
memory = ConversationBufferMemory()
memory.chat memory.add user message("Buenos dias!")
memory.chat memory.add ai message("Hello!")
memory.chat memory.add user message ("Whats your name?")
memory.chat memory.add ai message ("My name is GIGACHAT")
memory.load memory variables({})
{ 'history': 'Human: Buenos dias!\nAI: hello!\nHuman: Whats your
name?\nAI: My name is GIGACHAT'}
```

## LangChain - pamięć

```
llm = OpenAI(temperature=0)
conversation = ConversationChain(
    llm=llm, verbose=True, memory=ConversationBufferMemory()
)
conversation.predict(input="Buenos Dias!") # will it response in different
language?

" Hello! It's currently 9:00 AM here in my location. I am an AI programmed
to respond to human interactions. How can I assist you today?"
```

Jupyter notebook langchain\_examples.ipynb langchain\_chain.ipynb langchain\_memory.ipynb