# Generatywna sztuczna inteligencja z dużymi modelami tekstowymi

## Parameter-Efficient Fine-Tuning (PEFT)

Michał Żarnecki

# Parameter-Efficient Fine-Tuning (PEFT)

**PEFT (Parameter-Efficient Fine-Tuning)**

PEFT to ogólne podejście mające na celu poprawę efektywności procesu fine-tuningu modeli. Zamiast trenować wszystkie parametry modelu, w PEFT modyfikuje się tylko wybrane podzbiory parametrów, co pozwala na oszczędności w zasobach obliczeniowych i pamięciowych. PEFT znajduje zastosowanie w różnych technikach, takich jak LoRA, Adaptery czy Prefix Tuning.

# LoRA (Low-Rank Adaptation)

**LoRA (Low-Rank Adaptation)**

LoRA to jedna z metod PEFT, która wprowadza dodatkowe niskowymiarowe (low-rank) macierze w miejscu pełnych macierzy wag w modelu. Zamiast trenować wszystkie parametry modelu, LoRA optymalizuje tylko te niskowymiarowe macierze, co zmniejsza koszty trenowania i zwiększa efektywność obliczeniową. LoRA pozwala na adaptację dużych modeli do nowych zadań bez potrzeby modyfikowania oryginalnych wag modelu, co jest szczególnie przydatne przy pracy z bardzo dużymi modelami, jak GPT czy BERT.

# LLM fine-tuning

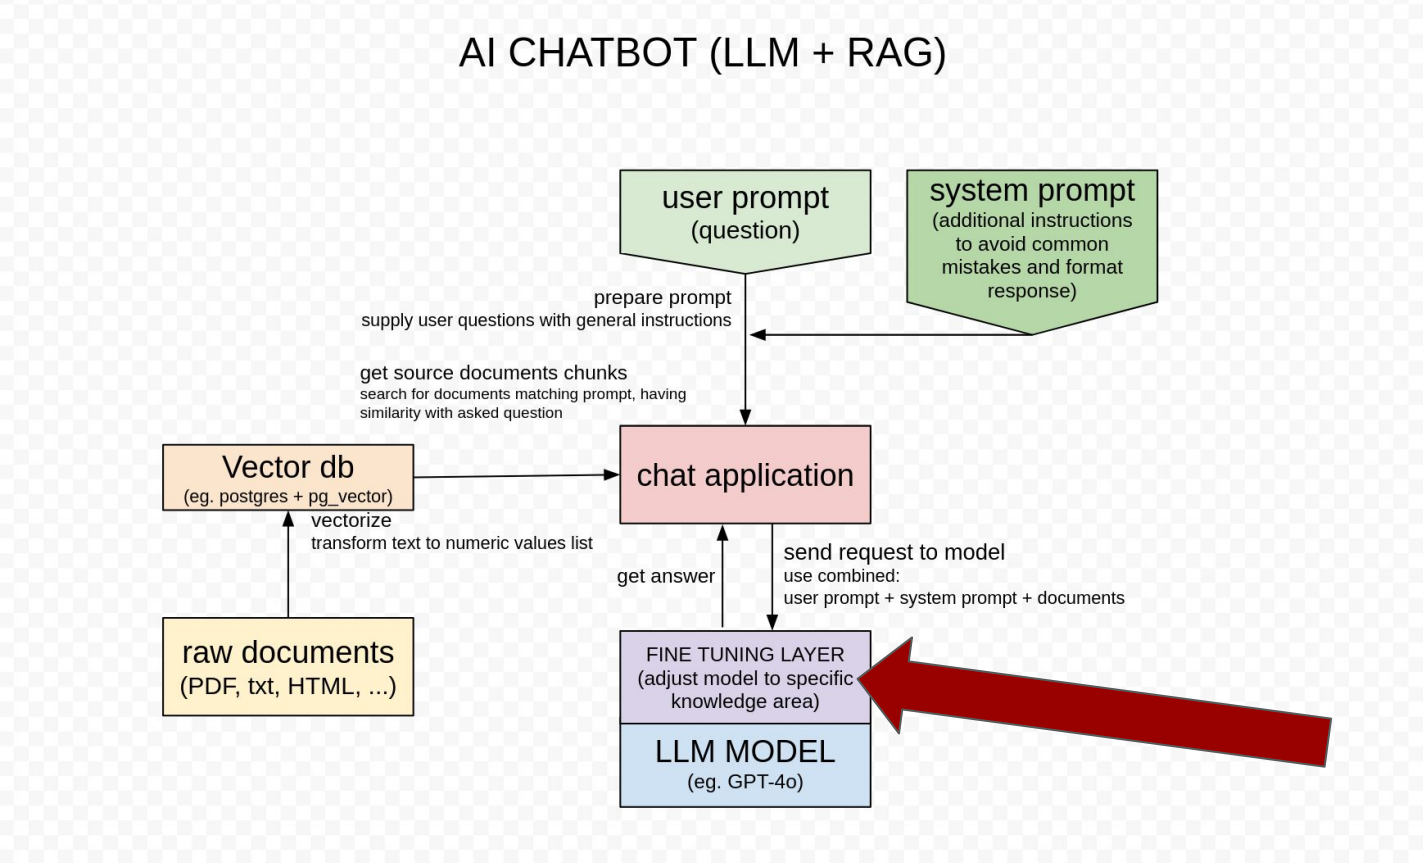

# Parameter-Efficient Fine-Tuning (PEFT)

https://www.kaggle.com/code/rzarno/llama3-fine-tuning-1-train
https://www.kaggle.com/code/rzarno/llama3-fine-tuning-2-merge-adapter
https://www.kaggle.com/code/rzarno/llama3-fine-tuning-3-convert
https://www.kaggle.com/code/rzarno/llama3-fine-tuning-4-quantize

# Parameter-Efficient Fine-Tuning (PEFT)

```
#based on article https://www.datacamp.com/tutorial/llama3-fine-tuning-locally?c

from transformers import (
    AutoModelForCausalLM,
    AutoTokenizer,
    BitsAndBytesConfig,
    HfArgumentParser,
    TrainingArguments,
    pipeline,
    logging,
)
from peft import (
    LoraConfig,
    PeftModel,
    prepare_model_for_kbit_training,
    get_peft_model,
)
import os, torch, wandb
from datasets import load_dataset
from trl import SFTTrainer, setup_chat_format
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
from huggingface_hub import login
from kaggle_secrets import UserSecretsClient
user_secrets = UserSecretsClient()

hf_token = user_secrets.get_secret("HuggingFace")

login(token = hf_token)

wb_token = user_secrets.get_secret("WandB")

wandb.login(key=wb_token)
run = wandb.init(
    project='Fine-tune Llama 3 8B on Medical Dataset',
    job_type="training",
    anonymous="allow"
)
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
base_model = "/kaggle/input/llama-3/transformers/8b-chat-hf/1"
dataset_path = "/kaggle/input/industry-examples/industry_examples_v2.csv"
new_model = "llama-3-8b-chat-industry-fine-tuned-guidelines-examples"
```

```
torch_dtype = torch.float16
attn_implementation = "eager"
```

```
# QLoRA config
bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch_dtype,
    bnb_4bit_use_double_quant=True,
)

# Load model
model = AutoModelForCausalLM.from_pretrained(
    base_model,
    quantization_config=bnb_config,
    device_map="auto",
    attn_implementation=attn_implementation
)
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
# Load tokenizer
tokenizer = AutoTokenizer.from_pretrained(base_model)
model, tokenizer = setup_chat_format(model, tokenizer)
```

```
# LoRA config
peft_config = LoraConfig(
    r=16,
    lora_alpha=32,
    lora_dropout=0.05,
    bias="none",
    task_type="CAUSAL_LM",
    target_modules=['up_proj', 'down_proj', 'gate_proj', 'k_proj', 'q_proj', 'v_proj', 'o_proj']
)
model = get_peft_model(model, peft_config)
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
import os.path
os.path.isfile(dataset_path)
```

```
#Importing the dataset
dataset = load_dataset('csv', data_files=dataset_path)
dataset = dataset.shuffle(seed=65)

def format_chat_template(row):
    row_json = [{"role": "user", "content": row["guideline"]},
                {"role": "assistant", "content": row["key"]}]
    row["text"] = tokenizer.apply_chat_template(row_json, tokenize=False)
    return row

dataset = dataset.map(
    format_chat_template,
    num_proc=4,
)

dataset['train']['text'][3]
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
training_arguments = TrainingArguments(
    output_dir=new_model,
    per_device_train_batch_size=1,
    per_device_eval_batch_size=1,
    gradient_accumulation_steps=2,
    optim="paged_adamw_32bit",
    num_train_epochs=1,
    evaluation_strategy="steps",
    eval_steps=0.2,
    logging_steps=1,
    warmup_steps=10,
    logging_strategy="steps",
    learning_rate=2e-4,
    fp16=False,
    bf16=False,
    group_by_length=True,
    report_to="wandb"
)
```

```
trainer = SFTTrainer(
    model=model,
    train_dataset=dataset["train"],
    eval_dataset=dataset["train"],
    peft_config=peft_config,
    max_seq_length=512,
    dataset_text_field="text",
    tokenizer=tokenizer,
    args=training_arguments,
    packing= False,
)
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
trainer.train()
```

```
wandb.finish()
model.config.use_cache = True
```

```
messages = [
    {
        "role": "user",
        "content": "Welches Wirtschaftszweig passt am besten zu dem unten beschriebenen Unternehmen?: Ticos Syst
    }
]

prompt = tokenizer.apply_chat_template(messages, tokenize=False,
                                       add_generation_prompt=True)

inputs = tokenizer(prompt, return_tensors='pt', padding=True,
                   truncation=True).to("cuda")

outputs = model.generate(**inputs, max_length=150,
                         num_return_sequences=1)

text = tokenizer.decode(outputs[0], skip_special_tokens=True)

print(text.split("assistant")[1])
```

# Parameter-Efficient Fine-Tuning (PEFT)

```
trainer.model.save_pretrained(new_model)
trainer.model.push_to_hub(new_model, use_temp_dir=False)
```

# Parameter-Efficient Fine-Tuning (PEFT) - merge adapter to model

```
from huggingface_hub import login
from kaggle_secrets import UserSecretsClient
user_secrets = UserSecretsClient()

hf_token = user_secrets.get_secret("HuggingFace")
login(token = hf_token)
```

```
base_model = "/kaggle/input/llama-3/transformers/8b-chat-hf/1"
new_model = "/kaggle/input/llama3-fine-tuning-1-train/llama-3-8b-chat-industry-fine-tuned-guidelines-examples/"
```

# Parameter-Efficient Fine-Tuning (PEFT) - merge adapter to model

```
from transformers import AutoModelForCausalLM, AutoTokenizer, pipeline
from peft import PeftModel
import torch
from trl import setup_chat_format
# Reload tokenizer and model
tokenizer = AutoTokenizer.from_pretrained(base_model)

base_model_reload = AutoModelForCausalLM.from_pretrained(
        base_model,
        return_dict=True,
        low_cpu_mem_usage=True,
        torch_dtype=torch.float16,
        device_map='auto',
        trust_remote_code=True,
)

base_model_reload, tokenizer = setup_chat_format(base_model_reload, tokenizer)

# Merge adapter with base model
model = PeftModel.from_pretrained(
    base_model_reload,
    new_model,
)

model = model.merge_and_unload()
```

# Parameter-Efficient Fine-Tuning (PEFT) - merge adapter to model

```
messages = [{"role": "user", "content":"How much is 2+2"}]

prompt = tokenizer.apply_chat_template(messages, tokenize=False, add_generation_prompt=True)
pipe = pipeline(
    "text-generation",
    model=base_model_reload,
    tokenizer=tokenizer,
    torch_dtype=torch.float16,
    device_map="auto",
)

outputs = pipe(prompt, max_new_tokens=120, do_sample=True,temperature=0.05, repetition_penalty=1.5)
print(outputs[0]["generated_text"])
```

```
model.save_pretrained("llama-3-8b-industry-code-with-adapter")
tokenizer.save_pretrained("llama-3-8b-industry-code-with-adapter")
```

```
model.push_to_hub("llama-3-8b-industry-code-with-adapter", use_temp_dir=False)
tokenizer.push_to_hub("llama-3-8b-industry-code-with-adapter", use_temp_dir=False)
```

# Kwantyzacja

Kwantyzacja modelu LLM (Large Language Model) to proces optymalizacji dużych modeli językowych poprzez zmniejszenie precyzji numerycznej wag i aktywacji, co prowadzi do mniejszego zużycia pamięci i szybszych obliczeń. W przypadku LLM, takich jak GPT czy BERT, kwantyzacja jest szczególnie przydatna, ponieważ modele te mają miliardy parametrów, co czyni je kosztownymi pod względem pamięci i czasu przetwarzania.
Cel kwantyzacji w LLM:

Kwantyzacja LLM ma na celu zmniejszenie wymagań obliczeniowych, bez znaczącego pogorszenia wydajności modelu w zadaniach takich jak generowanie tekstu, rozumienie języka, tłumaczenie itp. Dla LLM, kwantyzacja umożliwia uruchamianie modeli na urządzeniach z ograniczonymi zasobami lub przyspiesza inferencję na serwerach w chmurze.

- Redukcja precyzji liczb
- Kwantyzacja wag
- Kwantyzacja aktywacji

# Parameter-Efficient Fine-Tuning (PEFT) - kwantyzacja

```
%cd /kaggle/working
!git clone --depth=1 https://github.com/ggerganov/llama.cpp.git
%cd /kaggle/working/llama.cpp
!sed -i 's|MK_LDFLAGS   += -lcuda|MK_LDFLAGS   += -L/usr/local/nvidia/lib64 -lcuda|' Makefile
!LLAMA_CUDA=1 conda run -n base make -j > /dev/null
```

```
%cd /kaggle/working/

!./llama.cpp/llama-quantize /kaggle/input/llama3-fine-tuning-3-convert/llama-3-8b-industry-code.gguf llama-3-8b-industry-code-Q4_K_
M.gguf Q4_K_M
```

# Parameter-Efficient Fine-Tuning (PEFT) - kwantyzacja

```
from huggingface_hub import login
from kaggle_secrets import UserSecretsClient
from huggingface_hub import HfApi
user_secrets = UserSecretsClient()
hf_token = user_secrets.get_secret("HUGGINGFACE_TOKEN")
login(token = hf_token)

api = HfApi()
api.upload_file(
    path_or_fileobj="/kaggle/working/llama-3-8b-industry-code-Q4_K_M.gguf",
    path_in_repo="llama-3-8b-industry-code-Q4_K_M.gguf",
    repo_id="rzarno/llama-3-8b-industry-code",
    repo_type="model",
)
```

Jupyter notebook:
https://github.com/rzarno/course-generative-ai-python/blob/main/transformers_fine_tune.ipynb

# RLHF - Reinforcement Learning on Human Feedback

Reinforcement Learning from Human Feedback (RLHF) to technika stosowana w trenowaniu modeli uczenia maszynowego, gdzie algorytmy uczenia wzmacniającego są doskonalone poprzez wykorzystanie opinii ludzi.
RLHF łączy tradycyjne uczenie wzmacniające z ocenami i wskazówkami dostarczonymi przez ludzi, aby lepiej dostosować modele do oczekiwań użytkowników.

## Kroki:

1. **Generowanie odpowiedzi przez model**: Model (np. LLM, czyli Large Language Model) generuje różne odpowiedzi na zapytania użytkownika.
2. **Ocena przez człowieka**: Ludzie oceniają generowane odpowiedzi, wskazując, które są bardziej trafne, przydatne lub etyczne.
3. **Zastosowanie uczenia wzmacniającego**: Na podstawie tych ocen, model dostosowuje swoje przyszłe odpowiedzi, przyznając "nagrody" za bardziej pożądane odpowiedzi, a "kary" za te mniej pożądane. Celem jest maksymalizacja oczekiwanej sumy nagród w dłuższym okresie.

# RLHF - Reinforcement Learning on Human Feedback

```
def reward function(response):
    # Użyj modelu detekcji toksyczności, który zwraca wartość toksyczności w przedziale [0, 1]
    toxicity_score = toxicity_model.predict(response)

    # Ustaw próg toksyczności. Wszystko poniżej 0.3 jest akceptowalne
    threshold = 0.3

    if toxicity score < threshold:
        # Jeśli odpowiedź jest nietoksyczna, przyznaj pozytywną nagrodę
        return 1.0
    else:
        # Jeśli odpowiedź jest toksyczna, przyznaj ujemną nagrodę
        return -1.0
```